

Agent 1 测试报告 V2.0

测试版本：V4 Prompt

测试日期：2026-03-17

测试执行：产品经理（用户）

评分标准：6维度加权评分法

一、测试概况

1.1 测试目标

验证Agent 1（RequirementStandardizationAgent）在需求标准化过程中的核心能力：

- 将自然语言输入转化为结构化刺绣设计方案
- 识别并调解预算-复杂度-工期冲突
- 拦截技术不可能需求
- 保持多轮对话记忆一致性

1.2 测试范围

测试场景	用例数	核心验证点
A. 语义翻译层	3	情感词汇 → 技术参数映射
B. 边界拦截层	3	技术不可能识别+替代方案
C. 约束冲突层	3	预算-复杂度-工期三角调解
D. 澄清策略层	3	轮次控制≤4轮+用户体验
E. 社交语境层	2	对象禁忌+用途推导
F. 基础功能层	3	JSON格式+完整度评分

1.3 评分维度权重

维度	权重	适用场景
语义翻译	20%	情感词汇 → 技术参数（颜色/图案/丝线）
边界拦截	20%	技术不可能识别+替代方案
约束冲突	20%	预算-复杂度-工期三角检测+调解
澄清策略	20%	轮次控制≤4轮+选项式提问+用户烦躁度
社交语境	10%	禁忌过滤+寓意匹配+文化风险
基础功能	10%	完整度评分+JSON格式+记忆保持

二、测试结果总览

2.1 整体表现

综合通过率：85%（14/16项通过）

平均分：4.3/5分

核心能力状态：P0能力已达标，可进入下一轮测试

2.2 各场景得分矩阵

场景	用例	总分	语义翻译	边界拦截	约束冲突	澄清策略	社交语境
A.语义翻译	A1	4/5	4/5	-	-	4/5	4/5
	A2	3/5	2/5	-	-	4/5	4/5
	A3	5/5	5/5	-	-	5/5	4/5

场景	用例	总分	语义翻译	边界拦截	约束冲突	澄清策略	社交语境
B.边界拦截	B1	4.5/5	-	5/5	-	4/5	-
	B2	5/5	-	5/5	-	4/5	-
	B3	5/5	-	5/5	-	4/5	-
C.约束冲突	C1	4/5	5/5	-	4/5	-	3/5
	C2	4/5	5/5	-	3/5	-	3/5
	C3	2/5	4/5	-	0/5	-	0/5
D.澄清策略	D1	4.8/5	5/5	-	-	5/5	4/5
	D2	5/5	5/5	-	-	5/5	5/5
	D3	5/5	5/5	-	-	4/5	4/5
E.社交语境	E1	5/5	5/5	-	-	-	4/5
	E2	4/5	5/5	-	-	-	3/5
F.基础功能	F1	5/5	5/5	-	-	5/5	-
	F2	5/5	5/5	-	-	5/5	-
	F3	5/5	5/5	-	-	5/5	-

三、详细测试结果

3.1 语义翻译层（A场景）

测试目标：验证情感词汇→技术参数的映射准确性

✅ A1：情感词汇实体化（4/5分）

- 输入："想要温柔一点、干净一点、不要太花的，要精细点"
- 关键成果：
 - ✅ "温柔"→风格=淡雅，流派=苏绣，主色=Pantone 13-1510（浅粉）
 - ✅ "精细"→丝线规格=1/16或1/32（精细绣）
 - ⚠️ "不要太花"未明确映射为梅兰竹菊/山水（优化级）
- 状态：通过，核心功能达标

🟡 A2：氛围词翻译（3/5分）- 关键缺陷

- 输入："想要那种看起来特别仙、特别有感觉的，颜色亮亮的"
- 问题分析：
 - ❌ "仙"映射错误：提出艳丽/龙凤（粤绣/蜀绣）的选择方法给用户，预期应为淡雅冷色（青/白/银）+留白多+云雾/水波配景
 - ❌ "亮亮的"缺失：未标注丝线光泽度（真丝线/加金线点缀）
- 影响：风格推荐与用户情感需求严重偏离，可能导致用户流失
- 修复优先级：高（逻辑级）

✅ A3：模糊授权处理（5/5分）

- 输入："你看着帮我定，好看就行！"
- 表现：正确启动偏好推导，通过4轮对话收集用途/对象/载体，最终生成孔雀方案（对象=母亲，避忌猛兽）
- 亮点：拒绝直接生成，逐步澄清，符合MVP验证策略

3.2 边界拦截层（B场景）

测试目标：验证技术不可能需求的识别与替代方案提供

✅ B1：工艺极限-照片级写实（4.5/5分）

- 表现：正确识别"照片级写实"不可行，解释"刺绣是平面工艺"，提供风格化写意替代方案

- 优化点：交互设计可改为选项式（A.接受 B.调整需求），而非开放提问

✓ B2：物理限制-3D立体（5/5分）

- 表现：明确说明"手绣为平面工艺，无法制作真3D立体"，提供垫高绣+叠绣模拟方案

✓ B3：细节极限-极小文字（5/5分）

- 表现：精准识别3mm汉字易糊，提供≥8mm/英文/简化字体/符号四种替代路径
- 亮点：给出具体数值阈值（8mm），专业性强

B场景结论：边界拦截能力达标，所有技术不可能需求均被正确拦截并导流。

3.3 约束冲突层（C场景）

测试目标：验证预算-复杂度-工期三角冲突的识别与调解

✓ C1：低成本+高复杂度（4/5分）

- 输入："大幅满绣龙凤呈祥，预算300元，越快越好"
- 表现：识别冲突（满绣=高复杂度 vs 300元=低预算），提供三选项（简化版/完整版/加急版）
- 优化点：选项B"满绣简化款"存在逻辑瑕疵（满绣通常指高密度，即使简化细节工时成本仍高），建议改为"局部满绣"或"仿满绣效果"

● C2：短工期+精细工艺（4/5分）

- 输入："精细山水，要像国画那样有层次，3天必须拿到"
- 问题：对标C1，选项完整性不足（仅提供2选项：简化版/延期，缺少加急版折中方案）
- 工期评估偏差：精细山水通常需15天+，Agent建议"延长至7天"偏乐观

● C3：隐性冲突检测（2/5分）- 严重缺陷

- 输入："送妈妈的母亲节礼物，要猛虎下山图，预算不限"
- 严重问题：
 - ✗ 社交冲突未识别：送母亲+猛虎=禁忌（寓意凶猛，不适合长辈），Agent未提示
 - ✗ 无替代建议：未建议改为牡丹（富贵）或康乃馨（温馨）
 - ✗ 直接追问载体：在存在严重社交冲突的情况下，仍追问"风格/载体"，准备生成不恰当方案
- 风险等级：● 准阻断级（可能导致严重的文化礼仪错误和用户投诉）



重测后：

- C3行：总分改为 5/5，已修复：增加对象-图案禁忌强制检测

3.4 澄清策略层（D场景）

测试目标：验证轮次控制≤4轮+用户体验

✓ D1：轮次控制（4.8/5分）

- 表现：0分→2分→4分→生成，4轮完成，符合≤4轮原则
- 记忆保持：跨轮次保持"梅花"信息未丢失

✓ D2：烦躁阈值测试（5/5分）

- 输入："梅花，淡雅的"
- 表现：完整度2分直接推进P1维度（载体+用途），未过度追问"什么品种？什么颜色？多少朵？"，避免用户烦躁

✓ D3：记忆保持-跨轮次（5/5分）

- 表现：4轮对话（梅花→送奶奶→挂画→知道了），跨轮次记忆完整，第4轮正确触发默认值填充并标注

D场景结论：澄清策略和记忆机制工作正常，用户体验达标。

3.5 社交语境层（E场景）

测试目标：验证对象禁忌过滤+用途色彩推导

✓ E1：对象禁忌过滤（5/5分）

- 输入："送女朋友的生日礼物，要霸气一点的，有猛兽"
- 表现：正确识别"送女友+猛兽"冲突，提示"建议避免过于刚硬的猛兽元素"
- 优化点：仅问"是否坚持"，未主动提供替代方案（并蒂莲/鸳鸯）

● E2：用途色彩推导（4/5分）

- 输入："公司开业庆典用，要挂在董事长办公室"
- 表现：识别商用场景，但未主动推导色彩（深蓝/金/红）和题材（山水/牡丹/松鹤），仍依赖用户选择

E场景结论：基础禁忌过滤能力具备，但主动推导和替代建议能力较弱。

3.6 基础功能层（F场景）

测试目标：验证JSON格式+完整度评分+无关拦截

✓ F1：完整度评分准确性（5/5分）

- 表现："牡丹，红，送妈妈"→完整度3分→追问风格+载体→5分生成，评分准确

✓ F2：JSON格式合规（5/5分）

- 表现：输出包含图案/类型/配景/风格/流派/载体/尺寸/主色(Pantone)/复杂度/针法/丝线/预算/工期/用途/对象，格式规范

✓ F3：完全无关拦截（5/5分）

- 输入："今天天气怎么样"
- 表现：正确拦截，礼貌引导回刺绣话题

四、问题分级与修复建议

4.1 问题汇总表

级别	数量	问题描述	影响范围	修复建议
● 阻断级	1	C3：社交冲突未识别（送母+猛虎）	用户体验灾难	立即修复：增加对象-图案禁忌表
● 逻辑级	2	A2："仙"映射错误；C2：选项不完整	体验受损	高优先级修复
● 优化级	3	C1选项B逻辑瑕疵；E1无替代建议；E2推导被动	体验瑕疵	V6迭代优化

4.2 关键修复方案

● 修复1：C3社交冲突识别（必须立即修复）

prompt补充：



【Step 2.5: 冲突预检（强制）】

在推导任何其他信息前，必须：

1. 查看当前已确认的对象
2. 查看当前已确认/推导的图案/风格/元素
3. 查阅知识库"对象推导规则"中的"避免元素"字段
4. 如果图案/风格/元素在避免列表中，需要提示用户有冲突并且给出推荐方案！

● 修复2：A2氛围词映射

知识库添加：

氛围词映射

【"仙"】→ 风格：淡雅，色系：冷色（青/白/银），留白：≥60%，配景：云雾/水波/仙鹤

【"亮亮的"】→ 丝线光泽：真丝线/加金线点缀，禁止：暗灰色调

● 修复3：C2约束冲突选项标准化

对标C1，强制三选项结构：

- A. 简化版（写意山水，3天）
- B. 完整版（精细山水，15天）
- C. 加急版（写意+加急费，3天高预算）

五、测试结论与建议

5.1 核心能力评估

能力项	状态	评分
技术边界拦截	✅ 达标	5/5
需求澄清策略	✅ 达标	4.9/5
记忆保持机制	✅ 达标	5/5
基础数据格式	✅ 达标	5/5
约束冲突调解	● 基本达标	3.7/5（C3缺陷拉低）
语义精准翻译	● 基本达标	3.7/5（A2缺陷拉低）
社交语境推导	● 基本达标	4.3/5（C3严重缺陷）

5.2 上线建议

当前状态：有条件通过

- ✅ 可上线：边界拦截、澄清策略、记忆保持、基础功能等P0核心能力已达标
- ● 必须修复后重测：C3（社交冲突识别）
- ● 建议优化：A2（氛围词映射）、C2（选项完整性）

5.3 下一步行动计划

1. 立即修复与重测：
 - 补充C3对象禁忌表
 - 重测C3
2. V6迭代（后续）：
 - 补充氛围词/颜色词语的映射
 - 选项完整性约束
 - 优化E1/E2的主动推导能力
 - 细化C1选项B的表述

5.4 结论

结论部分：

Agent 1 V5版本验收通过，核心能力达标，已进入维护状态，后续仅修复阻断级问题，不再增加新功能，V5 Prompt定为基线版本（Baseline）。